

Nama : Raditya Zaki Athaya

NIM : 18223086

1. Sammon Mapping

Judul Video : Statistical Machine Learning | S23 | Lecture 8: Kernel PCA, SPCA, FDA, MDS, Sammon Mapping, Isomap

Nama Kanal : Benyamin Ghogh

URL Lengkap : <https://www.youtube.com/watch?v=ksNliTLpmNk&t=9381s>

(2:35:30-2:37:30)

Alasan Pemilihan Video : Video ini saya pilih karena berasal dari perkuliahan *machine learning* di level universitas yang membahas algoritma secara mendalam. Penjelasannya cukup detail, tidak hanya memberikan informasi mengenai preservasi struktur lokal pada data non-linier, tetapi juga membedah fungsi objektif matematis serta proses optimisasi iteratifnya (quasi-Newton method) secara terperinci.

1.1 Permasalahan yang Ingin Diselesaikan

Metode reduksi dimensi linier standar seperti Principal Component Analysis (PCA) dan Multidimensional Scaling (MDS) klasik sering kali gagal menangkap struktur data yang non-linier dan kompleks. Metode-metode ini terlalu berfokus pada pelestarian jarak yang jauh, sehingga ketika diaplikasikan pada dimensi rendah, titik-titik data cenderung saling menumpuk di satu area yang sama (*crowding effect*). Sammon Mapping hadir untuk mengatasi masalah penumpukan ini dengan memberikan perlakuan yang lebih adil pada jarak yang dekat.

1.2 Konsep Dasar Reduksi Dimensi

Sammon Mapping adalah metode reduksi dimensi non-linier yang bertujuan memproyeksikan data dari ruang berdimensi tinggi ke ruang berdimensi rendah (seperti 2D atau 3D). Konsep utamanya adalah memetakan titik-titik data sedemikian rupa sehingga distorsi jarak antara setiap pasangan titik pada dimensi asli dengan dimensi proyeksi dapat diminimalkan semaksimal mungkin.

1.3 Fungsi Objective (Sammon stress function)

Fungsi objektif dari Sammon Mapping diekspresikan sebagai:

$$E = \frac{1}{\sum d_{ij}} \sum \frac{(d_{ij} - d'_{ij})^2}{d_{ij}}$$

Persamaan ini berfungsi untuk mengukur tingkat "stres" atau error antara jarak asli (d_{ij}) dengan jarak setelah diproyeksikan (d'_{ij}). Bagian terpenting dari rumus ini adalah adanya variabel jarak asli (d_{ij}) sebagai pembagi (denominator) pada setiap pasangan titik. Adanya pembagi ini berperan sebagai "pemberi bobot". Jika jarak asli antar dua titik sangat kecil (keduanya bertetangga dekat), pembagian dengan angka kecil ini akan menghasilkan nilai error (penalti) yang sangat besar jika algoritma mencoba menjauhkan mereka di ruang proyeksi. Sebaliknya, pergeseran posisi pada titik yang memang aslinya saling berjauhan tidak akan diberi penalti sebesar itu. Dengan demikian, fungsi ini memaksa algoritma untuk memprioritaskan bentuk topologi lokal.

1.4 Prinsip Preservasi Jarak

Prinsip utama dari metode ini adalah preservasi struktur lokal. Sammon Mapping tidak terlalu memedulikan preservasi varians secara global (seperti PCA), melainkan memastikan bahwa titik-titik yang bertetangga di ruang dimensi tinggi tetap menjadi tetangga dan berdekatan di ruang dimensi yang lebih rendah.

1.5 Proses Optimisasi (iteratif/gradient descent)

Fungsi objektif (Sammon stress) di atas tidak memiliki solusi analitis pasti (*closed-form solution*). Oleh karena itu, optimisasi harus dilakukan secara iteratif. Algoritma biasanya dimulai dengan menentukan konfigurasi titik awal secara acak atau menggunakan hasil proyeksi dari PCA/MDS. Setelah itu, posisi titik-titik diperbarui langkah demi langkah untuk meminimalkan nilai error (E) menggunakan metode optimisasi berbasis kalkulus, seperti Gradient Descent atau metode turunan kedua seperti Newton's method (atau diagonal quasi-Newton seperti publikasi asli Sammon). Iterasi ini akan terus berjalan hingga fungsi stres konvergen dan titik minimum tercapai.

1.6 Kelebihan dan Keterbatasan

- Kelebihan: Sangat efektif dan unggul dalam memvisualisasikan dataset yang kompleks dan non-linier. Metode ini berhasil menghindari masalah crowding effect dengan mempertahankan kedekatan spasial di tingkat lokal, sehingga cluster data sering kali terlihat lebih terpisah dan jelas dibanding PCA.
- Keterbatasan: Proses optimisasi yang iteratif membuat komputasi Sammon Mapping berjalan cukup lambat dan membutuhkan sumber daya besar (khususnya untuk dataset berukuran besar). Selain itu, karena menggunakan metode optimisasi berbasis gradien, metode ini sangat rentan terjebak pada local minima, sehingga akurasi pemetaannya sangat dipengaruhi oleh posisi inisialisasi awal.

2. Spectral Analysis

Judul Video : 11: Spectral Analysis Part 1 - Intro to Neural Computation

Nama Kanal : MIT OpenCourseWare

URL Lengkap : <https://www.youtube.com/watch?v=4ip-4ai6kN8>

Alasan Pemilihan Video: Video ini saya pilih karena bersumber dari institusi akademik terkemuka (MIT) dan memberikan kerangka pemahaman yang sangat amat lengkap. Seri video ini tidak hanya menjelaskan teori dasar matematis (*Fourier Transform*), tetapi juga mengupas tuntas implementasi algoritmanya (*Fast Fourier Transform*) hingga ke aplikasi tingkat lanjut seperti pemfilteran sinyal dan pembuatan *Spectrogram*.

2.1 Konsep Domain Waktu vs Domain Frekuensi

Dalam analisis data, terdapat dua cara untuk melihat sebuah sinyal atau time-series:

- Domain Waktu (Time Domain): Memvisualisasikan bagaimana nilai data (misalnya amplitudo sinyal) berubah secara berurutan seiring berjalannya waktu.
- Domain Frekuensi (Frequency Domain): Menguraikan data untuk melihat tingkat kecepatan perubahan siklus atau pola periodik yang tersembunyi, sehingga sinyal direpresentasikan berdasarkan elemen-elemen frekuensi penyusunnya.

2.2 Transformasi Fourier

Transformasi Fourier adalah teknik matematis yang digunakan untuk mengubah data dari domain waktu ke domain frekuensi. Metode ini mendekomposisi fungsi (sinyal) yang rumit menjadi komponen-komponen dasarnya yang berupa gelombang kosinus dan sinus murni. Secara matematis, transformasi ini sangat bergantung pada Rumus Euler ($e^{i\omega t} = \cos(\omega t) + i \sin(\omega t)$), yang menyatukan gelombang sinus dan kosinus menjadi bentuk eksponensial kompleks sehingga komputasi spektral menjadi jauh lebih efisien.

2.3 Interpretasi Spektrum Frekuensi

Hasil dari Transformasi Fourier divisualisasikan dalam bentuk spektrum frekuensi (biasanya berupa *Power Spectrum*). Di mana sumbu horizontal mewakili nilai frekuensi, dan sumbu vertikal menunjukkan kekuatan (*power*) atau amplitudo. Untuk menginterpretasikannya, kita mencari puncak amplitudo (*amplitude peaks*), puncak-puncak ini mengidentifikasi frekuensi-frekuensi dominan yang menjadi penyusun utama dari sinyal atau data aslinya. Untuk analisis lanjutan, kita juga bisa menggunakan *Spectrogram*, yaitu visualisasi yang memperlihatkan bagaimana kekuatan berbagai frekuensi dalam suatu sinyal berubah dan berkembang seiring berjalannya waktu.

2.4 Contoh Aplikasi dalam Data Science

- **Noise Removal (Pembersihan Data):** Transformasi Fourier dapat digunakan untuk mendeteksi *line noise* atau kontaminasi frekuensi spesifik (misalnya, *noise* listrik 60 Hz pada alat perekam). Setelah terdeteksi di *power spectrum*, *noise* tersebut bisa langsung dihapus sebelum datanya dikembalikan ke bentuk sinyal awal.
- **Signal Processing:** Menggunakan *spectrogram* untuk mengekstraksi struktur spektral dari rekaman audio (seperti suara manusia) atau sinyal komputasi neural, guna memahami informasi temporal yang terkandung di dalamnya.