

Nama : Raditya Zaki Athaya
NIM : 18223086

Bagian 1 — Identifikasi Jenis Data

1.1 Dataset A

Jenis data dari dataset A adalah Low-dimensional data (Data berdimensi rendah). Dataset ini pada dasarnya hanya membandingkan dua variabel atau fitur utama, yaitu Temperature_C (Suhu) dan Defective_Products (Jumlah cacat).

Teknik visualisasi yang sesuai adalah Scatter Plot. Alasannya karena fiturnya hanya berjumlah dua (kurang dari atau sama dengan tiga), data ini sangat mudah dan cocok divisualisasikan secara langsung menggunakan *scatter plot* 2D untuk melihat pola korelasi atau hubungan linier/non-linier antara suhu mesin dan peningkatan jumlah produk cacat.

1.2 Dataset B

Jenis data ini adalah *High-dimensional data* (Data berdimensi tinggi). Dataset ini memiliki 5 fitur independen (Getaran, Suhu, Arus, Tekanan, Kebisingan) untuk setiap mesin.

Teknik visualisasi atau analisis yang sesuai untuk data ini adalah *Principal Component Analysis* (PCA), *Multidimensional Scaling* (MDS), atau *Sammon Mapping*. Alasannya karena manusia tidak dapat memvisualisasikan grafik dalam 5 dimensi sekaligus. Oleh karena itu, diperlukan algoritma reduksi dimensi untuk mengekstraksi informasi penting dan memproyeksikannya ke dalam 2D atau 3D *scatter plot* tanpa kehilangan terlalu banyak varians atau jarak antar titik aslinya.


1.3 Dataset C

Jenis dataset C adalah *Time series data* (Data deret waktu). Dataset ini merekam riwayat jumlah atau nilai (Production) yang berurutan secara temporal/waktu (Hour).

Teknik visualisasi yang sesuai yaitu *Line Chart* (untuk visualisasi waktu standar) dan *Spectral Analysis / Fourier Transform* (untuk analisis lanjutan pola periodik). Alasannya karena *Line chart* adalah cara paling intuitif untuk melihat fluktuasi produksi dari waktu ke waktu. Jika dicurigai ada pola yang berulang secara berkala (musiman), *Spectral Analysis* digunakan untuk mengubah data ini dari domain waktu ke domain frekuensi guna mendeteksi siklus produksinya.


Bagian 2 — Visualisasi Wajib

2.1 Pola hubungan pada Dataset A (Suhu vs Cacat Produk)



Berdasarkan *scatter plot* yang dihasilkan, terlihat adanya pola hubungan linier positif yang sangat kuat (dengan nilai korelasi sekitar 0.98) antara suhu mesin dan jumlah cacat produk. Artinya, seiring dengan peningkatan suhu mesin operasional pabrik, jumlah produk cacat yang dihasilkan juga ikut meningkat secara konsisten. Hal ini mengindikasikan bahwa suhu mesin (*Temperature_C*) merupakan faktor penyebab langsung atau indikator utama terjadinya cacat produksi pada pabrik tersebut.

2.2 Pola periodik pada Dataset C (Produksi per Jam)




Melalui visualisasi *line chart*, fluktuasi data produksi per jam menunjukkan pola periodik (siklus) yang sangat teratur dan berulang setiap 4 jam sekali. Produksi dimulai dari angka rata-rata (50 unit), mencapai puncaknya (58 unit) pada jam ke-2, ke-6, dan ke-10, lalu turun drastis ke titik terendah (42 unit) pada jam ke-4, ke-8, dan ke-12. Kemunculan pola gelombang harmonik ini sangat ideal jika dianalisis lebih lanjut menggunakan *Spectral Analysis (Fourier Transform)* untuk mengekstraksi frekuensi siklus operasional pabrik tersebut.

Bagian 3 — Analisis Data Berdimensi Tinggi

3.1 Penerapan PCA untuk Memproyeksikan Data Menjadi 2 Dimensi

Data sensor mesin (Dataset B) terdiri dari 5 fitur numerik: *Vibration*, *Temperature*, *Current*, *Pressure*, dan *Noise*. Sebelum menerapkan PCA, data terlebih dahulu distandarisasi (menggunakan *StandardScaler*) agar setiap fitur memiliki skala yang sama ($\text{mean} = 0$, $\text{varians} = 1$). Setelah itu, PCA diaplikasikan untuk mereduksi 5 dimensi fitur tersebut menjadi 2 komponen utama (*Principal Component 1* dan *Principal Component 2*).

3.2 Menampilkan Hasil Proyeksi (Scatter Plot 2D)



Dari hasil plot, terlihat bahwa *Principal Component 1* (PC1) saja sudah mampu merangkum 99.92% dari total varians (informasi) seluruh data sensor. Titik-titik mesin (M1 hingga M8) tersebar secara hampir linear di sepanjang sumbu PC1, yang mengindikasikan bahwa kelima parameter sensor mesin tersebut saling berkorelasi sangat kuat dan bergerak bersamaan.

3.3 Penjelasan Mengapa Teknik PCA Sesuai

Dataset B merupakan *high-dimensional data* karena memiliki 5 variabel independen (fitur). Secara visual, mustahil bagi manusia untuk membuat dan memahami grafik dalam ruang 5 dimensi secara langsung. Oleh karena itu, teknik PCA sangat sesuai karena mampu mengekstraksi informasi penting dan mengurangi dimensi data menjadi 2D (PC1 dan PC2) tanpa kehilangan karakteristik atau varians utama dari data aslinya. Dengan PCA, kita bisa memvisualisasikan persebaran profil kedelapan mesin secara sederhana, di mana mesin yang posisinya berdekatan (misalnya M1 dan M2) memiliki kondisi operasional/sensor yang mirip.

Lampiran

Lampiran 1 : Kode Visualisasi Pola hubungan pada Dataset A (Suhu vs Cacat Produk)

```
# Plot Dataset A: Scatter Plot
plt.figure(figsize=(8, 5))
plt.scatter(df_A['Temperature_C'], df_A['Defective_Products'],
            color='blue', alpha=0.7)
plt.title('Hubungan Suhu Mesin dan Jumlah Cacat Produk (Dataset A)')
plt.xlabel('Suhu Mesin (°C)')
plt.ylabel('Jumlah Cacat Produk')
plt.grid(True)
plt.tight_layout()
plt.savefig('scatter_A.png')
plt.show()
print(df_A.corr())
```

Lampiran 2 : Kode Visualisasi Pola periodik pada Dataset C (Produksi per Jam)

```
# Plot Dataset C: Line Chart
plt.figure(figsize=(10, 5))
plt.plot(df_C['Hour'], df_C['Production'], marker='o', linestyle='-',
         color='green')
plt.title('Jumlah Produksi per Jam (Dataset C)')
plt.xlabel('Jam Ke-')
plt.ylabel('Jumlah Produksi (Unit)')
plt.grid(True)
plt.xticks(df_C['Hour'])
plt.tight_layout()
plt.savefig('line_C.png')
plt.show()
```

Lampiran 3 : Kode Proyeksi PCA pada Dataset B

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
features = ['Vibration', 'Temperature', 'Current', 'Pressure', 'Noise']
X = df_B[features]
machines = df_B['Machine']
# Standardisasi Data
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# Terapkan PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
df_pca = pd.DataFrame(data=X_pca, columns=['PC1', 'PC2'])
# Visualisasi ke Scatter Plot 2D
plt.figure(figsize=(8, 6))
plt.scatter(df_pca['PC1'], df_pca['PC2'], color='purple', alpha=0.8,
s=100)
for i, txt in enumerate(machines):
plt.annotate(txt, (df_pca['PC1'][i] + 0.1, df_pca['PC2'][i]),
fontsize=11, fontweight='bold')
plt.title('Proyeksi PCA 2D untuk Data Sensor Mesin (Dataset B)')
plt.xlabel(f'Principal Component 1
({pca.explained_variance_ratio_[0]*100:.2f}%)')
plt.ylabel(f'Principal Component 2
({pca.explained_variance_ratio_[1]*100:.2f}%)')
plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```

Kode python dan visualisasi lengkap dapat dilihat pada notebook berikut : [Kode Python](#)